

PONTIFÍCIA UNIVERSIDADE CATÓLICA
Departamento de Engenharia Civil

1a. Avaliação:

Predição da altura significativa de ondas (Hs) em um ponto offshore próximo a Itaguaí/RJ por meio de Machine Learning

Relatório

Disciplina: EQM2118 – Modelagem Matemática com Aplicação de Inteligência Artificial

Alunos: Rafael Paes Leme (rafaelpaesleme@gmail.com)
Roberta da Silva Moreno (belmor80@gmail.br)

Data: 06 de outubro de 2026.

1. *Introdução*

Para compreender e prever o comportamento do mar na região offshore próxima a Itaguaí (RJ), utilizou-se o banco de dados *ERA5*. O *ERA5* é a quinta geração da reanálise produzida pelo Centro Europeu de Previsões Meteorológicas de Médio Prazo (ECMWF). A reanálise combina simulações numéricas e observações globais para produzir séries climatológicas multidecadais coerentes de variáveis atmosféricas, terrestres e oceânicas.

O banco de dados utilizado abrange o período de 1985 a 1994, totalizando 14.608 registros contínuos com intervalo de 6 horas. O conjunto reúne as seguintes variáveis meteoceanográficas:

- Vento: componentes zonal (u10) e meridional (v10), que representam o vento a 10 m acima da superfície, além de velocidade e direção.
- Ondas: altura significativa (Hs), período de pico (Tp) e direção de origem (Dir). Esses parâmetros caracterizam o clima de ondas no ponto offshore analisado.

A Figura 1 ilustra como o banco de dados está organizado.

Data	u10	v10	Velocidade_vento	Direcao_vento	Hs	Tp	Dir
1985-01-01 00:00:00	2.419418	-1.055252	2.639534	293.564880	0.985610	8.665382	112.390884
1985-01-01 06:00:00	2.060532	0.883026	2.241768	246.802795	0.904096	8.513527	112.494797
1985-01-01 12:00:00	2.663940	2.699005	3.792256	224.625397	0.843441	8.408058	115.437714
1985-01-01 18:00:00	5.098328	4.345490	6.698972	229.557846	0.917987	8.162941	131.719193
1985-01-02 00:00:00	3.138901	3.252182	4.519888	223.984543	0.974068	7.940285	139.274521

Figura 1. Organização do banco de dados.

O objetivo do trabalho é verificar quais informações de ondas e ventos ajudam a prever a altura significativa das ondas (Hs) com 12 e 24 horas de antecedência.

2. *Análise exploratória e Padrões Sazonais*

Antes da aplicação dos modelos preditivos, realizou-se uma análise exploratória para caracterizar o comportamento da série temporal. A Figura 2 apresenta as rosas de ondas e ventos. As ondas provêm predominantemente do quadrante sudeste, com maior ocorrência de Hs entre 0,5 e 1,4 m nas direções E-SE e de Hs entre 1,4 e 2,2 m nas direções SE-S. Os ventos são predominantemente de

nordeste. A Figura 3 evidencia o padrão sazonal de Hs: os maiores valores ocorrem principalmente entre maio e outubro, com destaque para setembro, enquanto o período de novembro a abril apresenta valores menores. Esse comportamento é compatível com a maior atuação de sistemas meteorológicos e frentes frias no período mais frio do ano. O percentil 90 de Hs é 2,16 m, isto é, apenas 10% dos registros superam esse valor. Esse limiar identifica os estados de mar mais elevados da série, mas não significa que todos eles correspondam necessariamente a tempestades ou ressacas. A análise confirma que a base apresenta padrões temporais e sazonais relevantes para a modelagem.

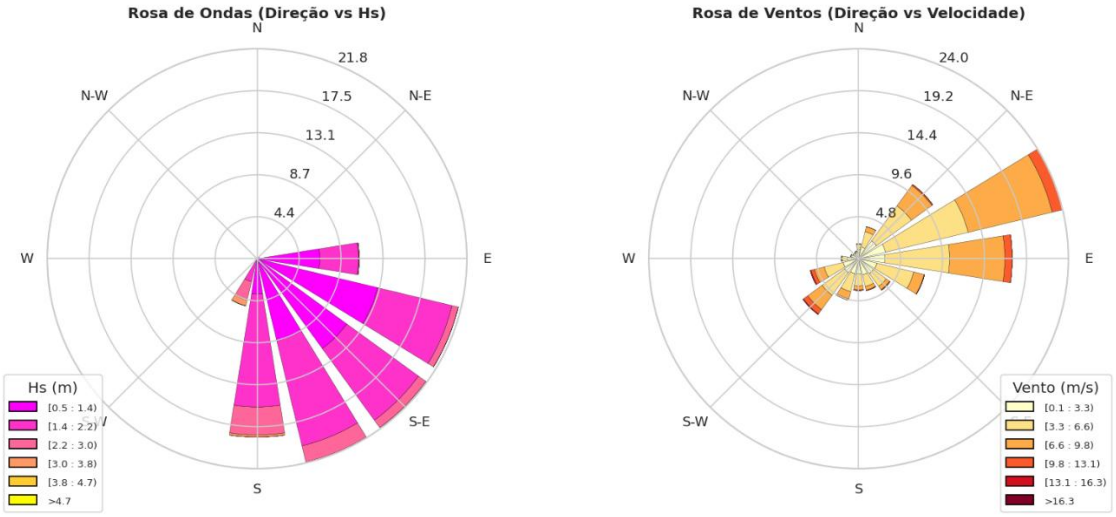


Figura 2. Rosa de Ondas – distribuição das alturas significativas e suas direções. Rosa dos Ventos – distribuição da direção do ventos e suas velocidades.

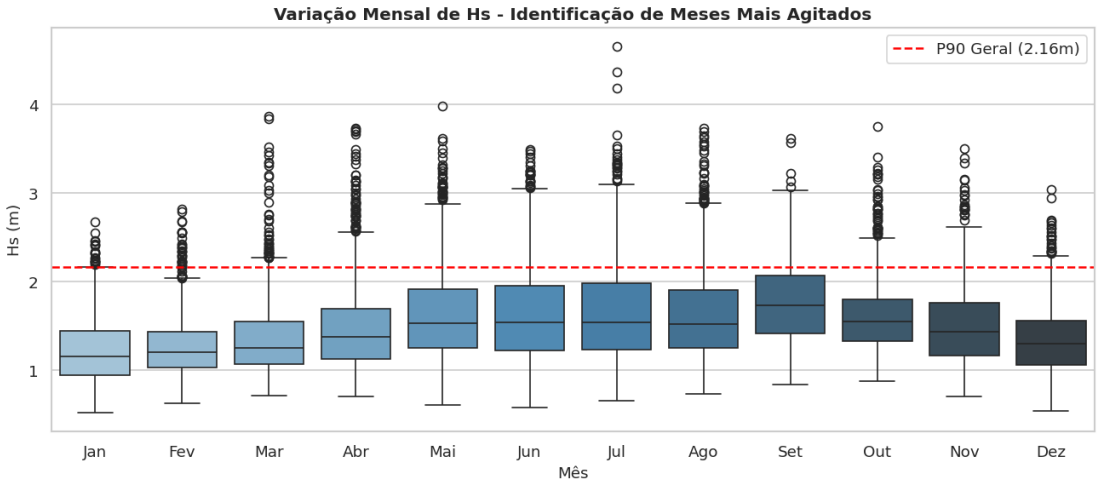


Figura 3.Distribuição das alturas de ondas por mês.

3. Correlação

A matriz da Figura 4 mostra correlação moderada de Hs com a velocidade do vento (0,47), com a direção das ondas (0,45) e com o período de pico (0,37). A relação com a velocidade do vento é fisicamente coerente, pois o vento participa da geração das ondas, mas a correlação não demonstra causalidade isolada. Além disso, correlações calculadas diretamente com direções em graus devem ser interpretadas com cautela, devido à natureza circular dessas variáveis.

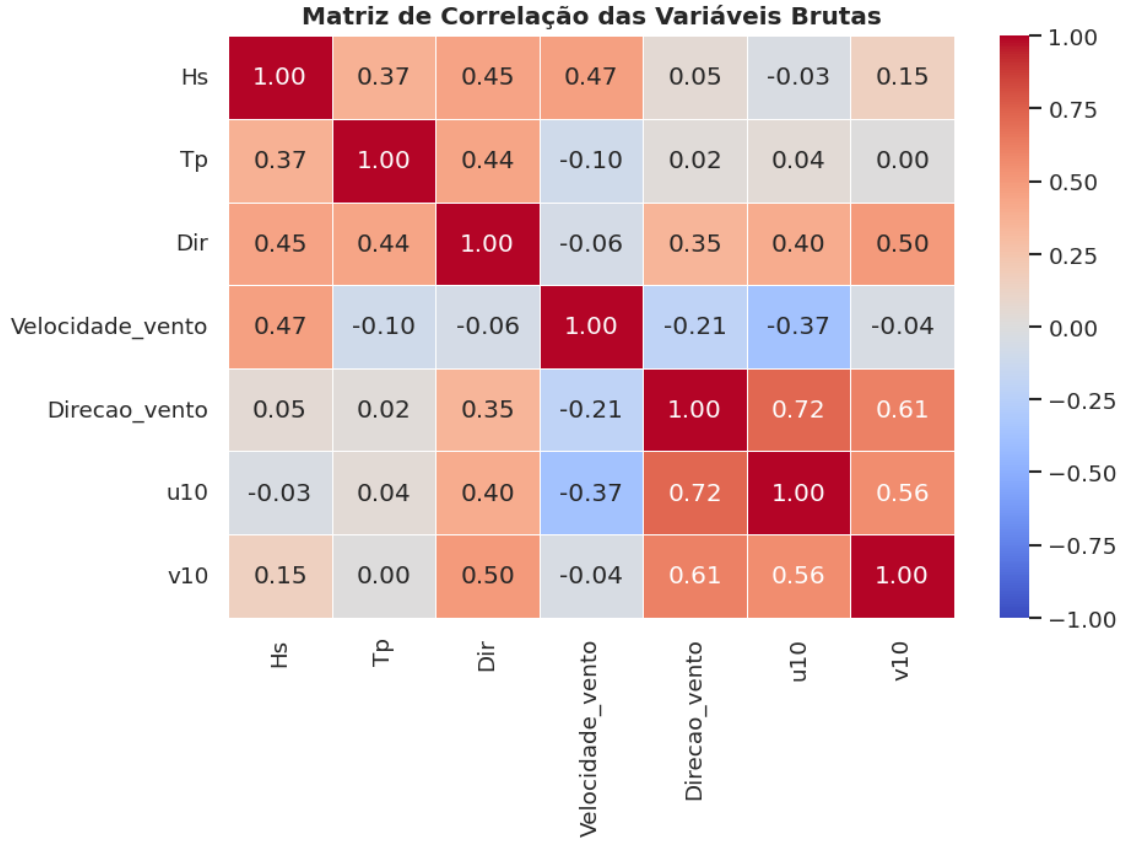


Figura 4. Matriz de correlação entre as variáveis.

4. Estruturação de predição

A meta do projeto é prever a altura significativa das ondas (Hs) com 12 e 24 horas de antecedência. Para representar a memória do estado do mar e evitar inconsistências no tratamento dos dados, foram aplicados os seguintes procedimentos:

1. Memória temporal: criaram-se variáveis com os valores observados 6, 12 e 24 horas antes, além das médias e dos máximos das últimas 24 horas;
2. Tratamento angular: as direções do vento e das ondas foram convertidas em seno e cosseno, evitando a descontinuidade numérica entre 0° e 360°, que representam a mesma direção;
3. Divisão temporal: os primeiros 80% dos dados foram destinados ao treinamento e os últimos 20% ao teste. A ordem cronológica foi preservada para impedir que informações futuras fossem usadas no treinamento.

5. Metodologia

Para avaliar a capacidade preditiva, compararam-se três abordagens: persistência, PCA seguido de regressão linear e regressão LASSO. Todos os atributos preditores foram padronizados com a média e o desvio-padrão calculados exclusivamente no conjunto de treinamento; a mesma transformação foi aplicada ao teste. Esse procedimento evita vazamento de informações do período de teste para o treinamento.

A persistência, definida por $Hs(t+\Delta t) = Hs(t)$, foi adotada como referência mínima: ela pressupõe que a altura da onda permanecerá igual ao valor atual. O PCA é uma técnica não supervisionada que combina variáveis correlacionadas e cria componentes principais independentes entre si. No treinamento, as 24 variáveis foram reduzidas a 11 componentes, preservando 95,81% da variância acumulada, e esses componentes alimentaram uma regressão linear. Como o PCA não utiliza o Hs futuro para criar as componentes, ele preserva os principais padrões gerais da base, que não são necessariamente os mais úteis para a previsão.

O LASSO é uma regressão supervisionada que atua diretamente sobre as variáveis originais. Neste estudo, adotou-se α = 0,01. A penalização L1 reduz os coeficientes e pode levar a zero aqueles associados a variáveis que pouco contribuem para prever o alvo. Assim, o método realiza previsão e seleção de atributos ao mesmo tempo. Das 24 variáveis, nove permaneceram com coeficientes diferentes de zero e 15 foram eliminadas do modelo.

O Hs atual apresentou o maior coeficiente no LASSO, resultado fisicamente coerente com a persistência temporal do estado do mar. Os sinais dos demais coeficientes representam contribuições condicionais dentro de um conjunto de variáveis correlacionadas e não devem ser interpretados isoladamente como relações de causa e efeito.

6. Comparação das Previsões

Aplicaram-se os métodos à previsão de Hs com 12 e 24 horas de antecedência. O MAE representa o erro absoluto médio em metros; o RMSE também mede o erro em metros, mas penaliza mais os erros elevados; e o R^2 indica a parcela da variabilidade de Hs explicada pelo modelo. Portanto, menores valores de MAE e RMSE e maior valor de R^2 indicam melhor desempenho.

Na previsão de 12 horas, o LASSO apresentou o melhor desempenho nas três métricas. O PCA teve MAE ligeiramente maior que a persistência, porém apresentou RMSE menor e R^2 maior. Na previsão de 24 horas, tanto o PCA quanto o LASSO superaram a persistência, e o LASSO novamente obteve os melhores resultados. O desempenho foi superior em 12 horas porque existe menos tempo para mudanças no vento, para a chegada de novos sistemas meteorológicos e para alterações do estado do mar.

Tabela 1 - Previsão para 12h.

Modelo	MAE (m)	RMSE (m)	R^2
Persistência	0.190	0.275	0.710
PCA + Regressão Linear	0.195	0.271	0.719
LASSO	0.175	0.248	0.763

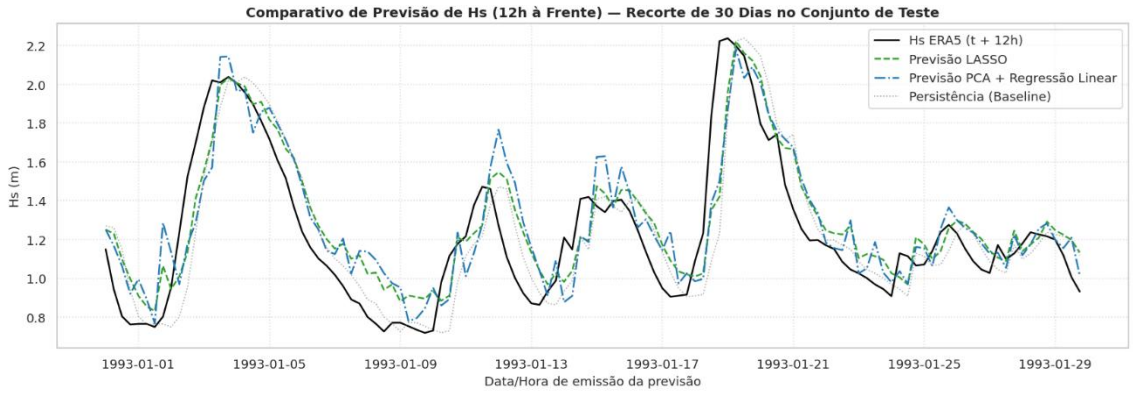
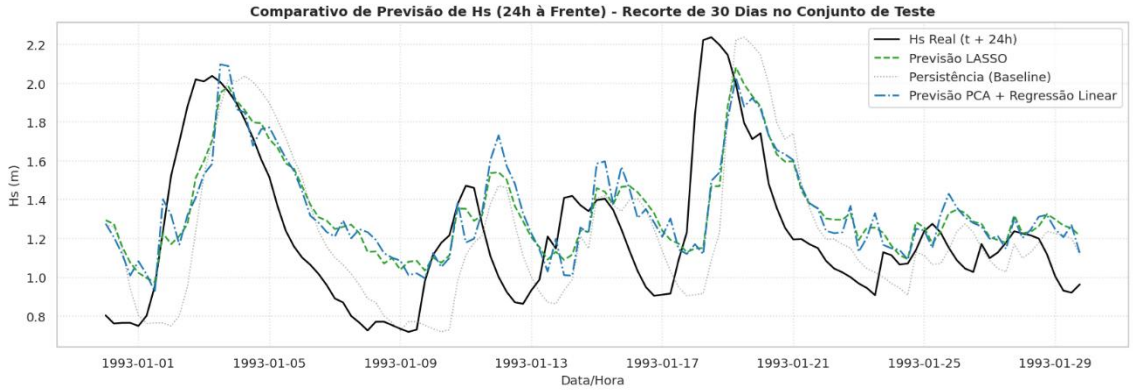


Tabela 2 - Previsão para 24h.

Modelo	MAE (m)	RMSE (m)	R^2
Persistência	0.309	0.432	0.285
PCA + Regressão Linear	0.278	0.382	0.439
LASSO	0.268	0.372	0.468



Conclusões e limitações

As condições atuais e anteriores de ondas e ventos mostraram-se úteis para prever Hs. O LASSO apresentou o melhor desempenho: para 12 horas, obteve MAE de 0,175 m, RMSE de 0,248 m e R^2 de 0,763; para 24 horas, MAE de 0,268 m, RMSE de 0,372 m e R^2 de 0,468. A perda de desempenho em 24 horas evidencia o aumento da incerteza com a antecedência.

A diferença decorre dos objetivos. O PCA resume a estrutura geral dos preditores sem utilizar a variável-alvo, enquanto o LASSO seleciona as variáveis diretamente relacionadas à previsão de Hs. Assim, o PCA foi eficiente para compactar a base e reduzir a multicolinearidade; o LASSO apresentou melhor previsão e interpretação. Os métodos são complementares: a escolha depende de o objetivo ser resumir os dados ou prever uma resposta específica.

Os resultados representam uma avaliação histórica em um ponto offshore do ERA5, não uma previsão operacional no Porto de Itaguaí. A aplicação local exigiria propagação das ondas até a costa, dados de validação e uma série mais longa. Trabalhos futuros também podem selecionar o parâmetro α por validação cruzada temporal e testar outros modelos.

7. Bibliografia

Anotações de aula da disciplina EQM2118.

Hastie, T.; Tibshirani, R.; Friedman, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer, 2017.

James, G.; Witten, D.; Hastie, T.; Tibshirani, R.; Taylor, J. An Introduction to Statistical Learning with Applications in Python. Springer, 2023.

Hersbach, H. et al. The ERA5 global reanalysis. Quarterly Journal of the Royal Meteorological Society, v. 146, p. 1999-2049, 2020.